

# Clustering par kmeans

L. Macaire - M1 IVI - RDF - Cours 8

11 mars 2014

# Motivations et objectifs du cours


## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8


## Introduction

Principes  
Algorithme  
Exemples

- Classification des données sans connaissance a priori
- Mise en oeuvre de la méthode K-means
- Segmentation d'une image multi-variée



Niveaux de gris rdf-2-classes-  
texture-1.png



Niveaux de texture rdf-2-  
classes-texture-1-text.png

# Motivations et objectifs du cours


## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8


## Introduction

Principes  
Algorithme  
Exemples

- Projection des pixels dans l'espace des attributs
- Mise en oeuvre de la méthode K-means



Espace d'attributs



Observations classées en 2 classes

# Motivations et objectifs du cours


## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

## Introduction

Principes  
Algorithme  
Exemples

- Classification des pixels par comparaison des distances observations-centres de gravité



Observations classées en 2 classes  
Image segmentée en 2 classes

# Matrice des données discrètes **X**

## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

## Introduction

Principes  
Algorithme  
Exemples

- Soient  $N$  observations pour chacune des  $D$  attributs  $X_i, i = 1, \dots, D$ .
- On peut donc représenter les  $N$  observations de l'attribut  $x_i$  sous la forme d'un vecteur

$$\mathbf{x}_i = (x_{i,1}, \dots, x_{i,j}, \dots, x_{i,N})^T$$

- On peut alors rassembler les  $D$  vecteurs d'attributs  $\mathbf{x}_i$  dans une matrice **X** de dimension  $D \times N$ .
- $x_{i,j}$  est donc le  $i$ eme attribut de la  $j$ eme observation.
- $\mathbf{x}$  est une observation quelconque de dimension  $D$ .

# Clustering par kmeans - Principes

## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

### Introduction

#### Principes

#### Algorithme

#### Exemples

- Soit  $K$  le nombre de classes  $C_k$  à retrouver, donné par l'utilisateur.
- L'algorithme kmeans va identifier les  $K$  centres de gravité  $\hat{\mu}_k$  des classes.
- Ils minimisent la distance entre les points assignés à chaque classe et les centre de gravité associés :

$$\frac{1}{N} \sum_{\mathbf{x}} (\mathbf{x} - \mu_{\hat{\omega}(\mathbf{x})})^T \cdot (\mathbf{x} - \mu_{\hat{\omega}(\mathbf{x})})$$

- où  $\hat{\omega}(\mathbf{x})$  est la classe d'assignation de la donnée  $\mathbf{x}$ .

# Clustering par kmeans -Principes

## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

### Introduction

#### Principes

#### Algorithme

#### Exemples

- Minimisation de la distance entre le centre de gravité et les points assignés à chaque classe :

$$\frac{1}{N} \sum_{\mathbf{x}} (\mathbf{x} - \boldsymbol{\mu}_{\hat{\omega}(\mathbf{x})})^T \cdot (\mathbf{x} - \boldsymbol{\mu}_{\hat{\omega}(\mathbf{x})})$$

- où  $\hat{\omega}(\mathbf{x})$  est la classe d'assignation de la donnée  $\mathbf{x}$ .
- $\hat{\omega}(\mathbf{x})$  est la classe dont le centre de gravité est le plus proche de  $\mathbf{x}$  :

$$\hat{\omega}(\mathbf{x}) = \operatorname{argmin}_k (\mathbf{x} - \boldsymbol{\mu}_k)^T \cdot (\mathbf{x} - \boldsymbol{\mu}_k)$$

# Clustering par kmeans - Algorithme

## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

### Introduction

Principes

Algorithme

Exemples

- Données d'entrée :  $K$  et  $\mathbf{X}$ .
- Soient les positions initiales des centres de gravité des classes  $\hat{\boldsymbol{\mu}}_k^{(0)}$ ,  $k = 1, \dots, K$ .
- $t = 1$
- Tant que critère d'arrêt non satisfait
  - Assignation des points aux  $K$  classes
$$\hat{\omega}(\mathbf{x})^{(t)} = \underset{k}{\operatorname{argmin}} (\mathbf{x} - \boldsymbol{\mu}_k^{(t-1)})^T \cdot (\mathbf{x} - \boldsymbol{\mu}_k^{(t-1)})$$
  - Soit  $S_k^{(t)}$  l'ensemble des points assignés à la classe  $k$ 
$$S_k^{(t)} = \{\mathbf{x}.tq.\hat{\omega}(\mathbf{x})^{(t)} = k\}$$
  - Mise à jour des centres de gravité des  $K$  classes
$$\boldsymbol{\mu}_k(t) = \frac{1}{|S_k^{(t)}|} \sum_{\mathbf{x} \in S_k^{(t)}} \mathbf{x}$$
  - $t = t + 1$



# Kmeans- Exemple 1

## Clustering par kmeans


L. Macaire -  
M1 IVI - RDF  
- Cours 8

## Introduction

Principes

Algorithme

Exemples



# Kmeans- Exemple 1

Clustering par  
kmeans


L. Macaire -  
M1 IVI - RDF  
- Cours 8

Introduction


Principes

Algorithme

Exemples



Assignation



Mise à jour des centres  $\hat{\mu}_k^{(1)}$

# Kmeans- Exemple 2

Clustering par  
kmeans


L. Macaire -  
M1 IVI - RDF  
- Cours 8

Introduction


Principes

Algorithme

Exemples



Espace d'attributs et  $\hat{\mu}_k^{(0)}$



$t=1$

# Kmeans- Exemple 2

Clustering par  
kmeans


L. Macaire -  
M1 IVI - RDF  
- Cours 8

Introduction


Principes

Algorithme

Exemples



t=2



t=3

# Limites de la méthode kmeans

## Clustering par kmeans

L. Macaire -  
M1 IVI - RDF  
- Cours 8

### Introduction

Principes

Algorithme

Exemples

- Sensible aux positions initiales des centres de gravité
- Nécessite de préciser le nombre  $K$  des classes
- Critères d'arrêt :
  - Nombre max d'itérations
  - seuil entre 2 itérations :  $\sum_k (\mu_k^{(t)} - \mu_k^{(t-1)})^T (\mu_k^{(t)} - \mu_k^{(t-1)})$
- Adaptée aux nuages sphériques